O que pensei ao estruturar a solução do problema:

Separei as disciplinas dos assuntos filhos.
Desconsiderei os filhos de nível 2, pois a pontuação é válida desde que o ramo esteja corretamente classificado. Classificando o nível 2, há uma maior chance de erro.
Vi a necessidade de uma limpeza da questão antes de prosseguir para as etapas de classificação.
Considerei uma classificação em 2 etapas, pois fazendo isso, reduz a quantidade de tokens utilizados e possibilita um maior foco do agente ao classificar utilizando um menor conjunto de opções. As etapas foram as seguintes:

1. Classificar as disciplinas, pois cada disciplina tem seu próprio conjunto de assuntos
2. Classificar o assunto dado a disciplina identificada.

Considerei também que como no cenário de produção haveria a necessidade de classificar milhares de questões, seria necessário que a execução ocorresse em paralelo. Um fator que contribuiu com isso foi a natureza do problema, cada classificação é independente da outra.
Como o problema é de classificação, usar um modelo de decisão, como o Jev, do Typesafe, seria mais adequado, como não havia descrição do que seria cada tema, o resultado obtido não foi satisfatório

Pontos que melhoraria se houvesse mais tempo em ordem de prioridade:

1. Criar uma coluna na tabela de temas contendo a descrição detalhada de cada assunto (gerado por uma LLM maior, como o Claude Sonnet/Opus).
2. Análise cuidadosa dos assuntos e questões.
2. Testar novamente o Jev contendo as descrições.
3. Testar o modelo atualmente utilizado com as descrições.
4. Fazer um benchmark entre os modelos de LLM

Fatores que atrapalharam um melhor resultado

A falta da descrição de cada tema foi um fator crítico, pois um problema bem detalhado traz melhores resultados.
Temas divididos em partes diferentes foi um outro ponto problemático, pois a diferença entre as partes está na cabeça de quem as dividiu.

Cenário de produção

Tipos de estratégias que poderiam ser utilizadas: Agentes, auxílio de RAG para consultar exemplos de questões antes de tomar uma decisão e revisão humana quando não houvesse confiança suficiente.
Custo obtido por questão neste teste: 0,0005 dólares
Medição de qualidade contínua: Poderia ser feita utilizando auditoria aleatória de algumas questões publicadas, reportes por 1000 questões publicadas ou por visualização (por exemplo).
O feedback dos alunos precisariam ser auditados e após isso, entraria como sugestão no prompt ou serviria como norte para modificação da descrição do assunto da questão.

Para o professor

Como citado anteriormente, é necessário que os assuntos sejam descritos.
Em relação aos assuntos com várias partes, se houver diferenças internas dentro de assunto, criar assuntos filhos, pois a nomenclatura não deve ser apenas para fins organizacionais, ela deve conter significado. Logo, mesmo que haja sentido manter como assuntos “irmãos”, ajustar a nomenclatura.
É importante também que a nomenclatura dos tópicos sejam revisadas por conta do problema relatado das “lixeiras”.